

**LAPORAN AKHIR MACHINE LEARNING
PERBANDINGAN CLIP (CONTRASTIVE LANGUAGE IMAGE
PRETRAINING) DAN SVM (SUPPORT VECTOR MACHINE)
DALAM KLASIFIKASI TIPE TUMOR OTAK DENGAN
MENGUNAKAN CITRA MRI**



Kelompok 8:

Rustian Afencius Marbun	122140155
Elsa Elisa Yohana Sianturi	122140135
Alfonso Pangaribuan	122140206
Muhammad Ghiffari Iskandar	122140189
Handayani	122140166
Alfajar	122140122
Joshua Palti Sinaga	122140141

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
2025**

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR GAMBAR.....	4
DAFTAR TABEL.....	5
BAB I.....	6
PENDAHULUAN.....	6
1.1 Latar Belakang Masalah.....	6
1.2 Rumusan Masalah.....	7
1.3 Tujuan Percobaan.....	8
1.4 Batasan Masalah.....	8
BAB II.....	9
DASAR TEORI.....	9
2.1 Citra Magnetic Resonance Image (MRI) pada Otak.....	9
2.2 Klasifikasi Tumor Otak.....	9
2.3 Preprocessing.....	10
2.4 Transformer.....	11
2.5 Contrastive Language–Image Pretraining (CLIP).....	12
2.6 Support Vector Machine (SVM).....	13
2.7 Metode Evaluasi.....	14
BAB III.....	16
METODOLOGI PENELITIAN.....	16
3.1 Diagram Alir Percobaan.....	16
3.2 Tahapan Percobaan.....	16
3.2.1 Pemilihan Dataset dan Pembagian Tugas.....	16
3.2.2 Exploratory Data Analysis.....	17
3.2.3 Preprocessing Data.....	18
3.2.5 Penerapan Model.....	18
3.2.6 Evaluasi dan Visualisasi Hasil.....	18
3.2.7 Analisis Hasil.....	19
BAB IV.....	20
HASIL DAN PEMBAHASAN.....	20
4.1 Pemilihan dan pemrosesan data.....	20
4.1.1 Karakteristik dan Akuisisi Dataset.....	20
4.1.2 Exploratory Data Analysis.....	21
4.1.3 Preprocessing Data.....	23
4.1.3.1 Augmentasi Data.....	24
4.1.3.2 Normalisasi Data.....	25
4.1.3.3 Label Encoding.....	25
4.1.3.4 Data Splitting.....	26
4.2 Hasil Pembangunan dan Pelatihan Model.....	26

4.2.1 Pembangunan Model SVM.....	27
4.2.2 Pelatihan Model SVM.....	27
4.2.3 Pembangunan Model CLIP.....	27
4.2.4 Pelatihan Model CLIP.....	29
4.3 Visualisasi Hasil Model.....	30
4.3.1 Visualisasi Kinerja Model CLIP.....	31
4.3.2 Visualisasi Kinerja Model SVM.....	33
4.3.3 Perbandingan Kinerja Visual SVM vs CLIP.....	35
4.4 Evaluasi Model.....	38
4.4.1 Nilai Evaluasi dan Interpretasi.....	39
4.5 Analisis Hasil.....	41
4.5.1 Analisis Kinerja Support Vector Machine (SVM).....	41
4.5.2 Analisis Kinerja Contrastive Language Image Pretraining (CLIP).....	41
4.5.3 Perbandingan Kinerja SVM dan CLIP.....	42
BAB V.....	43
KESIMPULAN.....	43
5.1 Ringkasan Hasil Percobaan.....	43
5.2 Saran.....	43
DAFTAR PUSTAKA.....	45
LAMPIRAN.....	47
<i>Figjam Brainstorming</i>	47
Bukti Bimbingan.....	47

DAFTAR GAMBAR

Gambar 2.3.1 Arsitektur Transformer.....	11
Gambar 2.5.1 Arsitektur CLIP.....	12
Gambar 2.6.1 Konsep SVM.....	13
Gambar 3.1.1 Diagram Alir Percobaan.....	16
Gambar 4.1.2.1 Distribusi dan Proporsi Jumlah Gambar per Kelas.....	22
Gambar 4.1.2.2 Sampel Gambar dari Setiap Kelas.....	22
Gambar 4.1.2.3 Distribusi Intensitas Piksel Keseluruhan Dataset.....	23
Gambar 4.4. Contoh Hasil Augmentasi pada Citra Glioma.....	24
Gambar 4.3.1.5 Confusion Matrix Model CLIP.....	31
Gambar 4.3.1.3 Training Loss pada Model CLIP.....	32
Gambar 4.3.1.4 Akurasi Validasi pada Model CLIP.....	33
Gambar 4.3.2.1 Confusion Matrix Model SVM.....	34
Gambar 4.3.3.1 Grafik Perbandingan Model secara Keseluruhan.....	35
Gambar 4.3.3.2 Grafik Perbandingan Precision berdasarkan Kelas.....	35
Gambar 4.3.3.3 Grafik Perbandingan Recall berdasarkan Kelas.....	36
Gambar 4.3.3.4 Grafik Perbandingan F1-Score berdasarkan Kelas.....	36
Gambar 4.3.3.5 Grafik Perbandingan Keseluruhan Model.....	36
Gambar 4.3.3.6 Grafik Perbandingan Akurasi Tes Model SVM dan CLIP.....	37
Gambar 4.3.3.7 Confusion Matrix SVM Setelah Normalisasi.....	37
Gambar 4.3.3.8 Confusion Matrix CLIP Setelah Normalisasi.....	38
Gambar 4.3.3.9 Grafik Perbandingan Jumlah Error pada Model SVM dan CLIP.....	38
Gambar 4.3.3.10 Grafik Persentase Peningkatan Model SVM dan CLIP.....	38

DAFTAR TABEL

Tabel 2.7.1 Metrik Evaluasi.....	13
Tabel 3.2.1 Pembagian Tugas Anggota Tim.....	16
Tabel 4.1.1 Jumlah gambar pada dataset.....	19
Tabel 4.1.2 Data sebelum normalisasi.....	24
Tabel 4.1.3 Data setelah normalisasi.....	24
Tabel 4.1.4 Tabel kelas hasil encoding.....	24
Tabel 4.1.5 Data Hasil Splitting.....	25
Tabel 4.2.1 Kombinasi Hyperparameter Tuning CLIP.....	28
Tabel 4.4.1 Perbandingan Nilai Precision SVM dan CLIP.....	38
Tabel 4.4.2 Perbandingan Nilai Recall SVM dan CLIP.....	38
Tabel 4.4.3 Perbandingan Nilai F1-Score SVM dan CLIP.....	39

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Tumor otak merupakan pertumbuhan sel abnormal yang terjadi pada jaringan otak dan dapat mengganggu fungsi sistem saraf pusat secara signifikan [1]. Insidensi penyakit ini terus mengalami peningkatan setiap tahunnya, baik di tingkat global maupun nasional, dan dapat menyerang individu dari berbagai kelompok usia, termasuk anak-anak. Berdasarkan asalnya, tumor otak diklasifikasikan menjadi dua jenis, yaitu tumor primer yang berasal dari jaringan otak itu sendiri, dan tumor sekunder (metastatik) yang berasal dari jaringan lain dalam tubuh dan menyebar ke otak dengan prevalensi kasus tumor sekunder lebih tinggi dibandingkan tumor primer [2]. Deteksi dini terhadap keberadaan tumor sangat krusial dalam menentukan strategi pengobatan yang tepat serta meningkatkan peluang kesembuhan pasien. Salah satu metode diagnosis yang paling efektif adalah melalui pencitraan medis, khususnya *Magnetic Resonance Imaging* (MRI), yang mampu menghasilkan citra resolusi tinggi tanpa menggunakan radiasi pengion, serta memiliki keunggulan dalam membedakan struktur jaringan lunak seperti *white matter* dan *gray matter* [3]. Dengan demikian, penggunaan citra MRI memegang peranan penting dalam membantu tenaga medis memvisualisasikan struktur otak secara mendetail dan melakukan diagnosis tumor otak secara lebih akurat [4].

Meskipun MRI memberikan citra berkualitas tinggi, interpretasi citra MRI secara manual oleh dokter spesialis radiologi memerlukan waktu yang lama dan dapat menjadi proses yang kompleks [5]. Selain itu, diagnosis berbasis pengamatan visual oleh pakar radiologi dapat bersifat subjektif dan berpotensi menghasilkan akurasi yang rendah. Metode diagnosis lain seperti biopsi juga memerlukan waktu cukup lama untuk memperoleh hasil laboratorium. Oleh karena itu, deteksi keabnormalan pada citra MRI secara otomatis sangat penting dalam mendukung proses diagnosis, guna meningkatkan akurasi, mempercepat waktu identifikasi, serta membantu dalam klasifikasi jenis tumor otak secara lebih efisien [6].

Berbagai penelitian menunjukkan efektivitas metode Support Vector Machine (SVM) dalam klasifikasi tumor otak berdasarkan citra MRI. Penelitian oleh Adam Jordie Sinulingga, Darwis Robinson Manalu, dan Samuel Manurung berjudul "*Klasifikasi Jenis Tumor Otak Berdasarkan Citra Glioma Menggunakan Metode Support Vector Machine*" mencapai akurasi 91% dalam klasifikasi glioma dan meningioma menggunakan fitur GLCM dan kernel linear [7]. Penelitian oleh Ainani Shabrina Febrianti pada tahun 2020 berjudul "*Klasifikasi Tumor Otak pada Citra Magnetic Resonance Image (MRI) dengan Menggunakan Metode Support Vector Machine (SVM)*" mencapai akurasi tertinggi 76%, menekankan pentingnya tahap *pre-processing* dan membandingkan berbagai kernel serta tipe SVM [8]. Penelitian oleh Wahyu Ardiantito S, Stacyana Jesika Surianto, Suci Ramadhani, dan Willy Pramudia Ananta pada tahun 2023 dengan judul "*Klasifikasi*

Tumor Otak Menggunakan Local Binary Pattern dan SVM Classifier" berhasil mengklasifikasikan tiga kelas tumor dengan akurasi 88% menggunakan fitur LBP dan kernel RBF [9]. Sementara itu, penelitian oleh Jihan Suci Ananda, Yoza Fendriani, dan Jesi Pebralia pada tahun 2024 berjudul "*Analisis Klasifikasi Penyakit Tumor Otak pada Citra Radiografi Menggunakan Metode Support Vector Machines (SVM) dengan Python*" berhasil mengklasifikasikan empat jenis tumor dengan akurasi 90% serta metrik evaluasi yang baik seperti F1-score dan RMSE [10].

Dalam studi berjudul "*Mammo-CLIP Framework for Multi-view Mammogram Analysis*", para peneliti mengevaluasi kinerja Mammo CLIP pada dua dataset, di mana model Mammo CLIP dengan backbone ViT-L/14 mencatatkan AUC sebesar 0.836 ± 0.019 dan akurasi 0.823 ± 0.015 , sedangkan ViT-B/16 mencapai AUC lebih tinggi sebesar 0.841 ± 0.017 , melampaui metode CNN dan cross-view transformer sebelumnya [11]. Pada studi lain berjudul "*Contrastive Patient-level Pretraining for Lung Cancer Risk Prediction*", pendekatan CLIP yang telah *diffinetune* menunjukkan performa unggul dengan AUC sebesar 0.895 untuk prediksi risiko kanker paru 2 tahun, mengungguli metode multimodal dan baseline lain secara signifikan ($p < 0.05$) [12]. Penelitian oleh Zhiyang Liu dkk. memperkenalkan *SeLIP* untuk pretraining kontras bahasa gambar pada MRI kepala multimodal, yang menunjukkan performa baik dalam berbagai tugas meskipun tidak dilaporkan angka AUC atau akurasi secara spesifik [13]. Studi CLIP pada prediksi respons *neoadjuvan* kanker rektum juga menunjukkan potensi dalam pengembangan strategi pengobatan yang dipersonalisasi dengan memanfaatkan fitur multimodal dari citra ERUS dan laporan medis [14]. Terakhir, penelitian Jie Liu dkk. dengan *CLIP-Driven Universal Model* untuk segmentasi organ dan deteksi tumor mencetak hasil menonjol seperti sensitivitas 0.968 dan spesifisitas 0.943 untuk deteksi tumor hati, serta menduduki peringkat pertama pada *Medical Segmentation Decathlon*, menunjukkan kekuatan transferabilitas dan kinerja tinggi pada berbagai dataset medis [14].

Penelitian ini bertujuan membandingkan efektivitas metode CLIP (*Contrastive Language-Image Pretraining*) dan SVM (*Support Vector Machine*) dalam klasifikasi tipe tumor otak menggunakan citra MRI. SVM telah banyak digunakan dengan hasil akurasi yang baik, sementara CLIP, sebagai pendekatan terbaru yang menggabungkan representasi multimodal bahasa dan gambar, menunjukkan potensi tinggi dalam meningkatkan akurasi dan kemampuan generalisasi pada data medis. Dengan membandingkan kedua metode tersebut, penelitian ini diharapkan dapat menentukan metode yang paling optimal untuk mendukung diagnosis otomatis tumor otak secara cepat, akurat, dan efisien, sehingga membantu tenaga medis dalam pengambilan keputusan klinis.

1.2 Rumusan Masalah

1. Bagaimana mengevaluasi kinerja metode *Support Vector Machine* (SVM) dan CLIP dalam mengklasifikasikan jenis tumor otak (*glioma, meningioma,*

pituitary, dan normal) berdasarkan citra MRI, dengan meninjau perbedaan hasil keduanya dari aspek akurasi, presisi, *recall*, dan F1-Score.

2. Bagaimana efektivitas dan efisiensi masing-masing metode dalam klasifikasi tipe tumor otak berdasarkan citra MRI, serta apa kelebihan dan keterbatasan dari tiap pendekatan yang digunakan?

1.3 Tujuan Percobaan

1. Untuk mengevaluasi dan membandingkan kinerja metode *Support Vector Machine* (SVM) dan CLIP dalam mengklasifikasikan jenis tumor otak (glioma, meningioma, *pituitary*, dan normal) berdasarkan citra MRI, menggunakan metrik akurasi, presisi, *recall*, dan F1-Score.
2. Untuk mengidentifikasi metode yang lebih optimal dalam klasifikasi tipe tumor otak dari segi efektivitas, efisiensi, serta kelebihan dan kekurangan masing-masing pendekatan.

1.4 Batasan Masalah

1. Data yang digunakan hanya berupa citra MRI otak yang sudah diklasifikasikan ke dalam empat kelas, yaitu glioma, meningioma, *pituitary*, dan normal.
2. Evaluasi kinerja metode hanya dilakukan menggunakan metrik akurasi, presisi, dan *recall* tanpa memasukkan metrik lain seperti *F1-score* atau AUC.
3. Pra-pemrosesan citra hanya mencakup tahapan standar yang relevan untuk kedua metode, tanpa melakukan eksplorasi pada teknik augmentasi data atau ekstraksi fitur lanjutan yang kompleks.
4. Perbandingan metode difokuskan pada efektivitas dan efisiensi dalam klasifikasi tipe tumor berdasarkan citra MRI, tanpa mempertimbangkan aspek lain seperti waktu pelatihan secara rinci atau kebutuhan sumber daya komputasi.
5. Penelitian ini tidak membahas aspek klinis lebih lanjut, seperti diagnosis pasien atau integrasi hasil klasifikasi dengan sistem medis nyata.

BAB II DASAR TEORI

2.1 Citra Magnetic Resonance Image (MRI) pada Otak

Magnetic Resonance Imaging (MRI) adalah teknik pencitraan medis yang memanfaatkan medan magnet kuat dan pulsa gelombang radio untuk menghasilkan citra struktur internal tubuh. Dalam konteks otak, inti *hidrogen* yang terdapat pada air dan lemak dalam jaringan akan menyesuaikan diri di bawah pengaruh medan magnet dan memancarkan sinyal ketika dikenai pulsa radio [15]. Sinyal ini kemudian diproses melalui transformasi *Fourier* untuk membentuk citra dua dimensi atau tiga dimensi dari struktur otak. Beberapa modalitas umum yang digunakan dalam MRI otak antara lain adalah *T1-weighted*, *T2-weighted*, dan *FLAIR*. Modalitas *T1-weighted* memberikan kontras tinggi terhadap struktur anatomi, sehingga jaringan lemak tampak cerah sedangkan cairan *serebrospinal* tampak gelap. Sementara itu, citra *T2-weighted* menonjolkan cairan dan *edema*, di mana cairan *serebrospinal* akan terlihat cerah. *FLAIR* (*Fluid-Attenuated Inversion Recovery*) merupakan teknik yang memblokir sinyal dari cairan bebas sehingga lesi yang berada di dekat ventrikel atau area berair dalam otak dapat terlihat lebih jelas [15].

2.2 Klasifikasi Tumor Otak

Klasifikasi tumor otak merupakan proses pengelompokan citra medis otak ke dalam kategori tertentu berdasarkan jenis dan karakteristik massa tumor yang terdeteksi. Tujuan utama dari klasifikasi ini adalah untuk membantu proses diagnosis secara lebih akurat dan efisien, sehingga pasien dapat menerima penanganan yang tepat sesuai dengan jenis tumor yang dimiliki. Dalam konteks klasifikasi tumor otak, klasifikasi label mengacu pada kategori yang menjadi target dari proses klasifikasi, seperti “*glioma*”, “*meningioma*”, “*pituitary adenoma*”, atau “*non-tumor*” (normal). Label ini biasanya ditentukan berdasarkan hasil diagnosis dokter spesialis radiologi atau patologi, dan digunakan sebagai *ground truth* saat melatih model klasifikasi [16].

Glioma adalah tumor yang berasal dari sel *glial*, yakni sel penunjang dalam sistem saraf pusat. Glioma cenderung bersifat infiltratif dan agresif, dengan variasi keganasan dari tingkat rendah (*low-grade*) hingga tinggi (*high-grade*). Ciri morfologinya dapat melibatkan bentuk yang tidak beraturan dan penyebaran ke jaringan sekitarnya, serta sering kali terlihat sebagai area *hipointens* atau *hiperintens* pada modalitas MRI tertentu tergantung derajat keganasannya [17].

Meningioma adalah tumor yang berasal dari sel *meninges*, yaitu lapisan pelindung otak dan sumsum tulang belakang. Tumor ini umumnya jinak dan tumbuh lambat, dengan batas yang jelas serta tekanan terhadap struktur otak di sekitarnya tanpa menembus jaringan otak itu sendiri. Pada citra MRI, *meningioma* biasanya tampak sebagai massa homogen yang menempel di *dura mater*. *Pituitary adenoma* adalah tumor jinak yang tumbuh di kelenjar *pituitari* atau *hipofisis*, yang berperan penting dalam pengaturan

hormon tubuh. Tumor ini bisa menyebabkan gangguan hormonal atau menekan struktur sekitarnya seperti saraf optik. Pada MRI, *pituitary adenoma* sering tampak pada area sela *tursika* dengan intensitas dan ukuran bervariasi tergantung pada jenisnya (*mikroadenoma* atau *makroadenoma*) [18].


2.3 Preprocessing

Preprocessing citra dalam konteks pencitraan medis khususnya merupakan konsep penting yang berkaitan dengan penyesuaian dan pengolahan awal data citra agar dapat dianalisis secara efektif oleh algoritma komputasi visual. Dalam ilmu komputer dan kecerdasan buatan, *preprocessing* dipahami sebagai serangkaian transformasi yang diterapkan pada data mentah untuk mengurangi variabilitas yang tidak relevan, menyamakan karakteristik data, dan mempersiapkan representasi yang lebih sesuai untuk proses pembelajaran mesin [19].

Dalam domain citra medis, *preprocessing* memiliki urgensi tersendiri karena citra sering mengandung informasi non-klinis, seperti bagian tulang tengkorak, artefak pemindaian, atau variasi intensitas akibat perbedaan perangkat MRI. Oleh karena itu, *preprocessing* sering kali mencakup prinsip-prinsip dasar seperti pemurnian area fokus (*region of interest*), normalisasi nilai piksel, penyesuaian dimensi, dan augmentasi data. Proses pemurnian citra bertujuan untuk memusatkan perhatian hanya pada bagian-bagian yang relevan secara klinis, sedangkan normalisasi dan standarisasi intensitas digunakan untuk menjaga konsistensi distribusi data antar-sampel [20].

Dalam teori pembelajaran mesin, *preprocessing* juga mencakup transformasi label atau anotasi menjadi format numerik yang dapat diproses secara algoritmik, serta perluasan dataset melalui teknik augmentasi guna memperkaya variasi tanpa menambah jumlah data secara aktual [20].

2.4 Transformer



Gambar 2.3.1 Arsitektur Transformer

Transformer adalah arsitektur *neural network* yang mengandalkan *self-attention* untuk memproses data sekuensial, di mana setiap elemen (token atau *patch* citra) dapat memperhatikan elemen lain secara dinamis. Berbeda dengan CNN yang menerapkan filter konvolusional lokal, *self-attention* menghitung bobot perhatian antar-semua pasangan elemen, sehingga dapat menangkap dependensi jangka panjang dan hubungan global dalam satu lapisan. Mekanisme ini sangat berguna untuk memahami konteks spasial penuh pada citra medis di mana area tumor bisa berada di lokasi yang sangat beragam [21].


Vision Transformer (ViT) merupakan citra yang dibagi menjadi *patch* kecil umumnya 16×16 atau 32×32 piksel yang kemudian di-*flatten* dan diproyeksikan ke dalam *embedding* berdimensi d kali d untuk mempertahankan informasi posisi spasial, setiap *patch embedding* ditambahkan dengan *positional encoding*, yaitu vektor *sinusoidal* atau parameter *trainable* yang menandai urutan *patch*. Hasilnya, setiap *patch* membawa informasi konten visual dan lokasinya, memungkinkan model membangun representasi komprehensif dari seluruh citra [21].

Blok dasar ViT terdiri dari *Multi-Head Self-Attention* (MHSA) dan *Feed-Forward Network* (FFN). MHSA membagi *embedding* menjadi beberapa “kepala” (*heads*) *attention* yang belajar pola hubungan yang berbeda pada level sub-ruang, lalu hasilnya digabung dan diproses oleh FFN (dua lapis linear dengan aktivasi GELU). Setiap blok diapit oleh layer *normalization* dan dilengkapi *residual connection*, menjaga stabilitas pelatihan dan memudahkan aliran gradien. Dengan menumpuk beberapa blok *attention*-FFN, ViT dapat mempelajari representasi visual yang dalam dan kaya konteks [22].

Keunggulan utama Transformer fleksibilitas dalam memodelkan relasi global dan kemudahan paralelisasi *training* membuatnya cepat beradaptasi ke domain medis. Dalam konteks klasifikasi tumor otak, Transformer dapat mengenali pola tekstur dan

kontras pada seluruh area otak, alih-alih bergantung pada fitur lokal saja. Lebih jauh, ketika dipadukan dengan metode *contrastive learning* seperti pada CLIP, *image encoder* transformer mampu menghasilkan *embedding* yang sangat informatif, mempermudah *downstream classifier* (misalnya *linear probe* atau SVM) untuk membedakan kelas tumor dengan akurasi tinggi [22].

2.5 Contrastive Language–Image Pretraining (CLIP)



Gambar 2.5.1 Arsitektur CLIP

Contrastive Language–Image Pretraining (CLIP) adalah metode pembelajaran multimodal yang dirancang untuk memetakan gambar dan teks ke dalam satu ruang *embedding* bersama, sehingga memungkinkan model memahami konten visual dan deskripsi tekstual secara simultan. CLIP memanfaatkan pasangan (*image, text*) dalam jumlah sangat besar hingga ratusan juta yang dihimpun dari internet tanpa kurasi manual. Dengan arsitektur dua *encoder* terpisah, image encoder (CNN seperti ResNet atau *Vision Transformer*) dan *text encoder* (Transformer), CLIP memproses input menjadi vektor berdimensi sama yang dinormalisasi menggunakan L2, lalu membandingkan kecocokan gambar teks melalui *cosine annealing* [22].

Prinsip inti CLIP terletak pada *contrastive learning* dengan InfoNCE *loss*, di mana model dilatih agar pasangan gambar dan teks yang benar memiliki *similarity* tinggi, sementara pasangan acak ditekankan agar *similarity*-nya rendah. *Loss* bersifat simetris, menghitung baik *embedding* gambar ke teks maupun teks ke gambar dalam satu batch berukuran N kali N , dengan suhu τ yang mengatur kekakuan distribusi probabilitas. Pendekatan ini memungkinkan CLIP belajar konsep visual abstrak dan hubungan semantik teks-gambar yang luas, sehingga menghasilkan kemampuan *zero-shot* yang impresif pada berbagai tugas visi komputer tanpa perlu *fine-tuning* khusus [23].

2.6 Support Vector Machine (SVM)



Gambar 2.6.1 Konsep SVM

Support Vector Machine (SVM) adalah algoritma pembelajaran mesin yang dirancang untuk menemukan *hyperplane* terbaik di ruang fitur berdimensi- p yang dapat memisahkan dua kelas data dengan margin terluas. SVM beroperasi dengan mencari sebuah “*hyperplane*” di ruang fitur p -dimensi yang memisahkan dua kelas data sedemikian rupa sehingga jarak minimum (margin) antara *hyperplane* dan titik-titik data terdekat dapat dimaksimalkan [24]. Secara matematis, *hyperplane* ini didefinisikan sebagai semua titik x yang memenuhi persamaan :

$$w^T x - b = 0,$$

Keterangan :

1. $w \in R^p$: vektor normal terhadap *hyperplane*, menentukan orientasi atau arah dari bidang pemisah.
2. $x \in R^p$: vektor fitur/data.
3. $b \in R^p$: bias atau konstanta *offset*, yang menentukan posisi *hyperplane* relatif terhadap titik asal (origin).

Pada SVM *hard-margin*, optimisasi bertujuan meminimalkan w ,

$$\frac{1}{2} \|w\|^2 \text{ dengan } y_i(w^T x_i - b) \geq 1, \forall i$$

Keterangan :

1. $\|w\|^2$: $w^T w$ norm kuadrat dari vektor w yang merepresentasikan kompleksitas model. Koefisien 0.5 ditambahkan demi kemudahan dalam proses turunan saat optimisasi.
2. $y_i \in (+1, -1)$: label kelas dari data ke- i .
3. $X_i \in R^p$: vektor fitur dari data ke- i .

Data yang tidak sepenuhnya linier-separabel, diperkenalkan *slack variables* ζ_i dan parameter regulasi C , yang mengizinkan beberapa pelanggaran *margin* dengan penalti $C \cdot \sum \zeta_i$, sehingga SVM *soft-margin* menjadi lebih toleran terhadap *noise* dan *overlap* antar kelas.

Tidak semua dataset dapat dipisahkan secara linier di ruang input asli, sehingga SVM memperluas kemampuannya dengan “kernel trick”. Fungsi kernel $k(x, z) = \langle \phi(x), \phi(z) \rangle$ memungkinkan SVM bekerja di ruang fitur berdimensi tinggi tanpa perlu menghitung transformasi ϕ secara eksplisit. Tiga kernel yang paling umum adalah linear,

polynomial, dan Radial Basis Function (RBF). Kernel RBF, khususnya, sering dipilih pada citra medis karena fleksibilitasnya dalam memodelkan batas keputusan non-linier yang kompleks kritis untuk membedakan morfologi tumor otak yang heterogen [24].

Pemilihan parameter C dan γ pada kernel RBF sangat menentukan performa SVM. Parameter C mengontrol kompromi antara margin lebar dan penalti kesalahan: nilai C kecil cenderung underfitting dengan margin luas, sedangkan C besar mendorong margin sempit demi meminimalkan kesalahan pada data pelatihan. Sementara itu, γ mengatur “jangkauan” pengaruh support vector γ kecil menghasilkan batas keputusan halus, sedangkan γ besar membuat batas lebih lokal dan rentan terhadap noise. Kombinasi optimal biasanya diperoleh melalui grid-search dan k-fold cross-validation pada data pelatihan [25].

Karena SVM menuntut input vektor berdimensi tetap, citra MRI perlu diubah menjadi deskriptor numerik. Ekstraksi fitur dapat mencakup histogram intensitas yang merekam distribusi frekuensi nilai piksel dalam region of interest, deskriptor tekstur seperti GLCM (*Gray-Level Co-occurrence Matrix*) dan LBP (*Local Binary Patterns*) untuk menangkap pola tekstur tumor, serta HOG (Histogram of Oriented Gradients) yang menghitung orientasi gradien per sel citra lalu dinormalisasi per blok guna menghadirkan ketahanan terhadap variasi pencahayaan. Alternatif sederhana adalah meratakan (*flatten*) semua piksel setelah *resizing* menjadi vektor tinggi, yang kemudian dapat direduksi dimensinya melalui PCA jika diperlukan untuk menjaga efisiensi komputasi [25].

2.7 Metode Evaluasi

Metode Evaluasi adalah ukuran kuantitatif yang digunakan untuk menilai kinerja suatu model dalam menyelesaikan tugas pembelajaran mesin, khususnya klasifikasi. Metrik ini membantu memahami seberapa baik model melakukan prediksi dibandingkan dengan label sebenarnya dalam data. Pemilihan metrik evaluasi yang tepat sangat penting karena masing-masing metrik memiliki fokus dan sensitivitas terhadap jenis kesalahan yang berbeda (misalnya kesalahan prediksi positif atau negatif) [25].

Pada tahap evaluasi, beberapa metrik utama digunakan untuk menilai kualitas klasifikasi:

Tabel 2.7.1 Metrik Evaluasi


Metrik	Definisi	Kegunaan
<i>Accuracy</i>	$\frac{\text{jumlah prediksi benar}}{\text{total sampel}}$	Proporsi prediksi benar dari total sampel.

<i>Precision</i>	$\frac{TP}{TP + FP}$	Rasio true positives terhadap total prediksi positif, penting untuk meminimalkan false positives.
<i>Recall</i>	$\frac{TP}{TP + FN}$	Rasio true positives terhadap total kondisi positif sebenarnya, penting untuk meminimalkan false negatives.
F1-Score	Harmonik rata-rata Precision & Recall: $2 \times \frac{Precision \times Recall}{Precision + Recall}$	Harmonik rata-rata precision dan recall, mencerminkan keseimbangan antara keduanya.

BAB III

METODOLOGI PENELITIAN

3.1 Diagram Alir Percobaan



Gambar 3.1.1 Diagram Alir Percobaan

3.2 Tahapan Percobaan

3.2.1 Pemilihan Dataset dan Pembagian Tugas

Pada tahap ini, sumber data utama diunduh dari Kaggle dan diorganisir ke dalam struktur folder yang mencerminkan kategori kelas (*glioma*, *meningioma*, *pituitary*, dan *no_tumor*) untuk memudahkan akses dan manajemen. Seluruh tim kemudian membagi tugas: satu bagian bertanggung jawab melakukan pengunduhan dan pengecekan kelengkapan data, bagian lain menyiapkan skrip otomatis untuk mengklasifikasi folder dan memberi label numerik, serta bagian ketiga menyiapkan *pipeline* awal untuk eksplorasi lebih lanjut. Dengan demikian, dataset sudah siap dalam format terstruktur sehingga siap diproses pada tahap-tahap selanjutnya.

Berikut merupakan tabel pembagian tugas anggota tim :

Tabel 3.2.1 Pembagian Tugas Anggota Tim

No	Nama	NIM	Role	Tugas Utama
1	Alfajar	122140122	Project Leader	Merancang alur dan desain riset, memahami konteks masalah, dan memimpin tim.
2	Elsa Elisa Yohana Sianturi	122140135	Data Analyst & Data Engineer	Eksplorasi data (EDA), pembersihan data, normalisasi, handling imbalance, transformasi fitur.
3	Joshua Palti Sinaga	122140141	ML Engineer	Membangun dan melatih model ML klasifikasi, tuning parameter, dan integrasi pipeline.
4	Rustian Afencius Marbun	122140155		
5	Muhammad Ghiffari Iskandar	122140189	Evaluator & Visualisasi Hasil	Menghitung metrik evaluasi, membuat grafik visualisasi hasil model, dan menyampaikan insight data.
6	Handayani	122140166	Dokumentasi & Github Manager	Menulis laporan, menyusun dokumentasi teknis (README), struktur folder, dan mengelola repository GitHub.
7	Alfonso Pangaribuan	122140206		

3.2.2 Exploratory Data Analysis

Setelah data terorganisir, dilakukan analisis eksploratori untuk memahami karakteristik dasar dataset, seperti distribusi jumlah sampel per kelas, variasi intensitas dan pola tekstur pada gambar MRI, serta deteksi *outlier* atau kesalahan *labeling*. Visualisasi seperti *bar chart*, *pie chart*, dan beberapa contoh gambar dari tiap kelas membantu memetakan kondisi ketidakseimbangan kelas dan kualitas citra. *Insight* dari EDA ini akan menjadi panduan dalam penentuan strategi augmentasi, normalisasi, dan teknik *encoding* label pada tahap *preprocessing*.

3.2.3 Preprocessing Data

Pada tahap *preprocessing*, citra-citra mentah diolah agar siap menjadi input model. Pertama dilakukan augmentasi misalnya rotasi, *flipping*, atau perubahan kontras untuk meningkatkan keragaman sampel dan mencegah *overfitting*. Selanjutnya setiap piksel dinormalisasi (skala 0–1 atau standardisasi) agar rentang intensitas citra seragam, dan label kelas diubah menjadi format numerik melalui label *encoding*. Hasilnya adalah dataset bersih, seimbang, dan konsisten yang siap diekstraksi fiturnya oleh model SVM maupun CLIP.

3.2.5 Penerapan Model

Dalam penelitian ini, dilakukan pemodelan klasifikasi tipe tumor otak menggunakan dua pendekatan yang berbeda, yaitu *Support Vector Machine* (SVM) dan *Contrastive Language–Image Pretraining* (CLIP). Model SVM digunakan sebagai baseline klasik yang mengandalkan fitur citra hasil ekstraksi menggunakan teknik ekstraksi fitur seperti *Principal Component Analysis* (PCA). Citra MRI terlebih dahulu diubah menjadi format *grayscale*, dinormalisasi, dan fiturnya diekstraksi sebelum digunakan sebagai input ke dalam model SVM. Parameter-parameter penting seperti kernel, C, dan gamma disetel menggunakan pencarian *grid* (*GridSearchCV*) untuk mendapatkan akurasi terbaik pada data uji.

Model CLIP memanfaatkan pendekatan multimodal dengan menggunakan arsitektur *pre-trained* dari OpenAI yang telah dilatih pada jutaan pasangan citra dan teks. Dalam pendekatan ini, setiap citra MRI pasien dipasangkan dengan deskripsi label teks, lalu diproses oleh *encoder* citra dan teks dengan CLIP untuk menghasilkan representasi *embedding*. Representasi ini kemudian digunakan dalam pelatihan jaringan klasifikasi tambahan (*custom classifier*) di atas CLIP untuk memetakan hasil *embedding* ke label tumor. Model CLIP ini dilatih secara *end-to-end* dengan hanya mengaktifkan *gradient* pada *layer classifier*, sementara *encoder* CLIP tidak diperbarui (*non-trainable*). agar representasi awal hasil pretraining tetap stabil dan tidak mengalami perubahan. Strategi ini dilakukan dengan tujuan memanfaatkan representasi umum yang telah dipelajari CLIP dari dataset berskala besar, sekaligus menghindari *overfitting* terhadap data domain medis yang relatif terbatas. Pemodelan CLIP ini melibatkan penyesuaian beberapa *hyperparameter* seperti *batch size*, *learning rate*, dan jumlah *epoch*.

3.2.6 Evaluasi dan Visualisasi Hasil

Untuk evaluasi model *Support Vector Machine* (SVM) dan CLIP dalam klasifikasi tipe tumor otak berdasarkan citra MRI, digunakan beberapa metrik evaluasi standar dalam domain klasifikasi, yakni akurasi, presisi, *recall*, dan *F1-score*. Metrik-metrik ini dipilih karena mampu memberikan gambaran yang komprehensif terkait performa model dalam mendeteksi masing-masing kelas, khususnya pada data medis yang umumnya memiliki distribusi kelas yang tidak seimbang.

Selain itu, digunakan *confusion matrix* untuk identifikasi pola kesalahan klasifikasi dan evaluasi seberapa baik model mampu membedakan antara kelas *glioma*, *meningioma*, *pituitary*, dan *no-tumor*. Untuk memberikan pemahaman visual terhadap kinerja model, dilakukan visualisasi hasil klasifikasi melalui *confusion matrix* yang divisualisasikan dalam bentuk *heatmap*, serta grafik perbandingan metrik evaluasi antara model SVM dan CLIP. Pada model CLIP, visualisasi tambahan dilakukan dengan menampilkan beberapa contoh citra beserta label prediksi dan probabilitas klasifikasinya untuk mengevaluasi kemampuan model dalam memahami relasi antara citra dan label deskriptif berbasis teks. Seluruh evaluasi dilakukan menggunakan data uji yang sebelumnya tidak dilibatkan dalam proses pelatihan, sehingga hasil evaluasi ini dapat merepresentasikan generalisasi model terhadap data baru. Pendekatan evaluasi ini bertujuan tidak hanya untuk mengukur performa numerik, tetapi juga memberikan insight interpretatif terhadap kekuatan dan kelemahan masing-masing pendekatan dalam konteks klasifikasi tumor berbasis citra MRI.

3.2.7 Analisis Hasil

Setelah dilakukan proses klasifikasi dan evaluasi menggunakan metode *Support Vector Machine* (SVM) dan *Contrastive Language–Image Pretraining* (CLIP), dilakukan analisis terhadap performansi masing-masing metode dalam mengklasifikasikan tipe tumor otak berdasarkan citra MRI. Evaluasi dilakukan dengan menggunakan metrik seperti akurasi, presisi, *recall*, dan *F1-score*, yang digunakan untuk mengukur sejauh mana model mampu melakukan prediksi dengan tepat. Selanjutnya, hasil evaluasi dari masing-masing metode dianalisis untuk melihat karakteristik kinerja, kelebihan, dan keterbatasan masing-masing pendekatan. Pembahasan difokuskan pada bagaimana metode konvensional seperti SVM, yang bergantung pada ekstraksi fitur manual, dibandingkan dengan pendekatan modern berbasis pembelajaran multimodal seperti CLIP, yang mampu memahami representasi visual secara kontekstual.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Pemilihan dan pemrosesan data

Tahap awal penelitian berfokus pada persiapan dataset citra MRI otak yang akan digunakan untuk melatih dan mengevaluasi model klasifikasi tumor.

4.1.1 Karakteristik dan Akuisisi Dataset

Penelitian ini memanfaatkan dataset citra MRI otak publik yang bersumber dari Kaggle, yaitu "Brain Tumor MRI Dataset" oleh Masoud Nickparvar. Dataset ini dipilih karena kelengkapannya, mencakup empat kelas yang relevan dengan tujuan penelitian yaitu glioma, meningioma, pituitari, dan non-tumor (citra otak sehat).

Dataset diunduh secara terprogram menggunakan pustaka kagglehub untuk memastikan *reproducibility*. Eksplorasi awal terhadap struktur direktori dataset mengonfirmasi bahwa data telah terorganisir ke dalam folder Training dan Testing, dengan masing-masing berisi subfolder untuk keempat kelas yang disebutkan.

Selanjutnya, dilakukan proses pemuatan (loading) dan preprocessing awal terhadap seluruh citra. Proses ini bertujuan untuk mengubah data mentah menjadi format yang siap diolah lebih lanjut. Langkah-langkah utamanya meliputi:

1. Pemuatan Citra

Seluruh citra dari direktori Training dan Testing dibaca menggunakan *library* OpenCV (cv2). Penggabungan ini dilakukan untuk mendapatkan gambaran keseluruhan dataset sebelum nantinya dibagi kembali untuk validasi.

2. Konversi Grayscale

Setiap citra dikonversi menjadi format *grayscale*. Langkah ini diambil untuk mereduksi kompleksitas komputasi dan memfokuskan analisis pada fitur tekstur dan bentuk, yang dianggap lebih relevan untuk deteksi tumor daripada informasi warna.

3. Penyesuaian Ukuran

Ukuran setiap citra diseragamkan menjadi 256×256 piksel. Standarisasi ukuran ini krusial untuk memastikan input yang konsisten bagi model *machine learning* yang akan digunakan.

Tabel 4.1.1 Jumlah gambar pada dataset

Dataset Split	Kategori	Jumlah Gambar
Training	Glioma	1.321 gambar

	Meningioma	1.339 gambar
	No Tumor	1.595 gambar
	Pituitary	1.457 gambar
	Glioma	300 gambar
Testing	Meningioma	306 gambar
	No Tumor	405 gambar
	Pituitary	300 gambar
	Glioma	300 gambar

Setelah proses pemuatan dan preprocessing awal selesai, diperoleh total 7023 citra yang siap digunakan.


4.1.2 Exploratory Data Analysis

Setelah akuisisi dan pemuatan data awal, *Exploratory Data Analysis* (EDA) dilakukan untuk memahami karakteristik fundamental dataset. Tahap ini krusial untuk mengidentifikasi distribusi data, mengamati kualitas visual citra, dan mendapatkan wawasan awal sebelum melangkah ke pra-pemrosesan yang lebih mendalam dan pemodelan. EDA ini mencakup analisis distribusi kelas, visualisasi sampel citra, dan analisis distribusi intensitas piksel.

Berikut adalah hasil dari EDA :

a. Distribusi Kelas

Untuk mengetahui komposisi dataset, dilakukan analisis terhadap jumlah gambar pada masing-masing dari empat kelas (glioma, meningioma, pituitary, dan notumor). Hasil analisis ini divisualisasikan dalam bentuk diagram batang dan diagram lingkaran seperti yang ditunjukkan pada Gambar 4.1.




Gambar 4.1.2.1 Distribusi dan Proporsi Jumlah Gambar per Kelas

Gambar 4.1.2.1 menunjukkan bahwa kelas 'notumor' memiliki jumlah terbanyak dengan ~2000 gambar (28.5%), diikuti oleh 'pituitary' dengan ~1750 gambar (25.0%), 'meningioma' dengan ~1650 gambar (23.4%), dan 'glioma' dengan ~1625 gambar (23.1%).

b. Visualisasi Sampel Citra

Untuk mendapatkan pemahaman kualitatif mengenai data, sampel acak citra dari setiap kelas divisualisasikan. Gambar 4.1.2.2 menyajikan empat contoh citra untuk masing-masing kelas, memberikan gambaran mengenai variasi penampilan MRI.




Gambar 4.1.2.2 Sampel Gambar dari Setiap Kelas

Gambar 4.1.2.2 menampilkan berbagai orientasi dan penampakan tumor (atau ketiadaannya) pada citra MRI, menyoroti variasi yang ada dalam dataset

c. Distribusi Intensitas Piksel

Analisis distribusi intensitas piksel dilakukan untuk memahami rentang nilai dan frekuensi kemunculan level keabuan pada keseluruhan dataset. Histogram pada Gambar 4.3 menampilkan distribusi ini



Gambar 4.1.2.3 Distribusi Intensitas Piksel Keseluruhan Dataset

Gambar 4.1.2.3 menunjukkan adanya puncak frekuensi yang sangat tinggi pada nilai piksel mendekati nol, serta distribusi yang lebih menyebar pada rentang nilai yang lebih tinggi, dengan ekor panjang ke arah nilai 255.

Secara keseluruhan, hasil Exploratory Data Analysis (EDA) memberikan wawasan krusial mengenai karakteristik dataset "Brain Tumor MRI Dataset". Analisis distribusi kelas, seperti yang ditunjukkan pada Gambar 4.1, mengungkapkan bahwa dataset ini memiliki komposisi yang relatif seimbang, dengan proporsi setiap kelas berkisar antara 23.1% hingga 28.5%. Keseimbangan ini merupakan kondisi awal yang menguntungkan, karena dapat meminimalkan risiko bias pada model klasifikasi dan mengurangi kebutuhan akan teknik penyeimbangan data yang kompleks.

Selanjutnya, inspeksi visual terhadap sampel citra (Gambar 4.2) mengonfirmasi adanya variasi visual yang signifikan, baik dalam hal bentuk, ukuran, lokasi, maupun kontras tumor antar kelas dan bahkan di dalam kelas yang sama. Meskipun terdapat perbedaan visual yang diharapkan dapat dipelajari model, kemiripan antar beberapa jenis tumor serta keberadaan area non-otak seperti tengkorak dan latar belakang luas mengindikasikan tantangan yang perlu diatasi. Informasi ini diperkuat oleh analisis distribusi intensitas piksel (Gambar 4.3), yang menyoroti dominasi area gelap (background) melalui puncak frekuensi tinggi di dekat nilai nol. Sebaran intensitas pada nilai yang lebih tinggi, meskipun menunjukkan adanya informasi kontras, juga menyiratkan perlunya normalisasi atau peningkatan kontras untuk menstandarisasi data dan menonjolkan fitur.

4.1.3 Preprocessing Data

Setelah tahap Analisis Eksplorasi Data (EDA), dataset citra MRI memerlukan serangkaian langkah pra-pemrosesan lebih lanjut. Tahap ini krusial untuk mengubah data menjadi format yang optimal, meningkatkan kualitasnya, dan mempersiapkannya


agar sesuai dengan kebutuhan model *machine learning* yang akan dibangun. Proses ini mencakup augmentasi data untuk memperkaya variasi, normalisasi nilai piksel, pengkodean label kelas, dan pembagian dataset menjadi set pelatihan, validasi, dan pengujian.

4.1.3.1 Augmentasi Data

Augmentasi data merupakan teknik penting, terutama dalam pengolahan citra, untuk meningkatkan jumlah dan keragaman data latih secara artifisial. Dengan membuat variasi baru dari citra yang ada, model diharapkan menjadi lebih tangguh (*robust*) dalam mengenali pola meskipun terdapat perbedaan orientasi, pencahayaan, atau deformasi minor. Hal ini juga berperan penting dalam mengurangi risiko *overfitting* pada model.

Berdasarkan kode yang dijalankan, beberapa teknik augmentasi telah didefinisikan dan divisualisasikan, antara lain:

1. Rotasi berlawanan arah jarum jam (*Anticlockwise Rotation*) dengan sudut acak.
2. Rotasi searah jarum jam (*Clockwise Rotation*) dengan sudut acak.
3. Pembalikan vertikal (*Flip Up Down*).
4. Penyesuaian kecerahan (*Brightness*) menggunakan *adjust_gamma*.
5. Pemberian efek buram (*Blur*) menggunakan *Gaussian Blur*.
6. Transformasi geser (*Sheared*) menggunakan *Affine Transform*.



Gambar 4.4. Contoh Hasil Augmentasi pada Citra Glioma

Pada gambar 4.4 menyajikan contoh visual dari penerapan fungsi-fungsi augmentasi ini pada sebuah sampel citra Glioma. Terlihat bagaimana satu citra asli dapat diubah menjadi berbagai versi baru, yang masing-masing membawa variasi geometris atau pencahayaan. Teknik-teknik ini dapat diintegrasikan ke dalam *pipeline* pelatihan untuk memastikan model "melihat" versi citra yang berbeda-beda pada setiap *epoch*, sehingga meningkatkan kemampuannya untuk generalisasi.

4.1.3.2 Normalisasi Data

Citra *grayscale* memiliki nilai intensitas piksel dalam rentang 0 hingga 255. Untuk meningkatkan stabilitas dan kecepatan konvergensi model, terutama algoritma seperti SVM yang sensitif terhadap skala fitur, nilai-nilai ini perlu dinormalisasi. Normalisasi dilakukan dengan mengubah rentang nilai menjadi [0, 1].

Berikut adalah data sebelum dan sesudah normalisasi :

Tabel 4.1.2 Data sebelum normalisasi

Sample	Nilai Piksel
Sample 1	[[0 0 0 ... 2 2 2], ..., [0 0 0 ... 0 0 0]]
Sample 2	[[2 2 2 ... 5 5 5], ..., [0 0 0 ... 0 0 0]]
Sample 3	[[0 0 1 ... 3 2 2], ..., [0 0 2 ... 1 3]]

Tabel 4.1.3 Data setelah normalisasi

Sample	Nilai Piksel
Sample 1	[[0.0 0.0 0.0 ... 0.0078 0.0078 0.0078], ..., [0.0 0.0 0.0 ... 0.0 0.0 0.0]]
Sample 2	[[0.0078 0.0078 0.0078 ... 0.0196 0.0196 0.0196], ..., [0.0 0.0 0.0 ... 0.0 0.0 0.0]]
Sample 3	[[0.0 0.0 0.0039 ... 0.0117 0.0078 0.0078], ..., [0.0 0.0 0.0078 ... 0.0039 0.0117]]

Hasil ini menunjukkan bahwa seluruh data citra (X) telah berhasil ditransformasi ke dalam rentang [0, 1], membuatnya siap untuk diproses lebih lanjut oleh model.

4.1.3.3 Label Encoding

Label kelas dataset ini awalnya berupa teks (glioma, meningioma, notumor, pituitary). Karena model *machine learning* memerlukan input numerik, label teks ini perlu dikonversi menjadi angka. LabelEncoder dari Scikit-learn digunakan untuk melakukan transformasi ini.

Hasil pemetaan (encoding) yang diperoleh dari eksekusi kode adalah sebagai berikut:

Tabel 4.1.4 Tabel kelas hasil encoding

Kelas	Encoding
Glioma	0
Meningioma	1
Notumor	2

Pituitary	3
-----------	---

Dengan demikian, setiap kelas kini diwakili oleh sebuah angka integer unik (0 hingga 3), yang akan menjadi target prediksi (variabel y) untuk model.

4.1.3.4 Data Splitting

Langkah krusial terakhir dalam persiapan data adalah membaginya menjadi tiga set terpisah. *Training Set* (untuk melatih model), *Validation Set* (untuk *tuning hyperparameter* dan pemantauan) yang berasal dari *Training Set*, dan *Test Set* (untuk evaluasi akhir). Pembagian yang tepat memastikan bahwa evaluasi kinerja model dilakukan secara objektif pada data yang belum pernah digunakan selama pelatihan.

Dataset dibagi dengan proporsi 60% (Latih), 20% (Validasi), dan 20% (Uji). Proses ini menggunakan fungsi `train_test_split` dari Scikit-learn. Parameter `stratify` digunakan untuk memastikan bahwa proporsi setiap kelas dipertahankan secara konsisten di ketiga set data, yang penting untuk evaluasi yang adil.

Tabel 4.1.5 Data Hasil Splitting

Jenis Data	Jumlah
Training	4213
Validation	1405
Testing	1405

Jumlah ini mengonfirmasi bahwa dataset (7023 citra) telah berhasil dibagi sesuai proporsi yang diinginkan. Distribusi kelas pada *test set* juga diperiksa untuk memastikan stratifikasi berjalan dengan baik. Dengan selesainya tahap ini, data kini sepenuhnya siap untuk digunakan dalam pembangunan dan pelatihan model SVM dan CLIP.

4.2 Hasil Pembangunan dan Pelatihan Model

Setelah data disiapkan melalui tahap pra-pemrosesan, langkah selanjutnya adalah pembangunan dan pelatihan model klasifikasi. Dalam penelitian ini, dua pendekatan model dieksplorasi: *Support Vector Machine* (SVM) sebagai *baseline* klasik, dan *Contrastive Language-Image Pre-Training* (CLIP) sebagai pendekatan modern yang memanfaatkan pemahaman multimodal.

4.2.1 Pembangunan Model SVM

Support Vector Machine (SVM) adalah algoritma *supervised learning* yang kuat untuk klasifikasi. Namun, SVM tradisional memerlukan input data dalam format vektor 1D dan sering kali mendapat manfaat dari *feature engineering* dan reduksi dimensi. Berikut adalah Pembangunan Model SVM.

Sebelum melatih SVM, data citra yang telah dinormalisasi perlu diolah lebih lanjut berikut adalah tahapannya.

1. Flattening.

Citra 2D (256×256) diubah menjadi vektor 1D. Berdasarkan output, setiap citra diubah menjadi vektor dengan 65.536 fitur.

2. Standardisasi.

StandardScaler diterapkan untuk menstandarkan fitur (memiliki rata-rata 0 dan standar deviasi 1), yang penting untuk kinerja SVM.

3. Reduksi Dimensi (PCA).

Mengingat tingginya jumlah fitur, *Principal Component Analysis* (PCA) digunakan untuk mereduksi dimensi. PCA diatur untuk mempertahankan 95% varians dari data asli. Hasilnya, dimensi fitur berhasil direduksi secara signifikan menjadi 873 fitur dari yang awalnya 65.536 fitur, Langkah PCA ini bertujuan untuk mengurangi kompleksitas komputasi dan potensi *noise* tanpa kehilangan sebagian besar informasi penting.

4.2.2 Pelatihan Model SVM

Model SVM diinisialisasi menggunakan *kernel Radial Basis Function* (RBF), dengan parameter $C=1.0$ dan $\gamma='scale'$. Model kemudian dilatih menggunakan data latih yang telah diproses (X_{train_pca}). Setelah latihan selesai, model dievaluasi pada *validation set* untuk mendapatkan estimasi awal kinerjanya. Hasil akurasi pada *validation set* adalah 89.47%. Akurasi ini menunjukkan bahwa model SVM memiliki kemampuan awal yang baik dalam mengklasifikasikan tumor otak berdasarkan fitur PCA yang diekstraksi. Kinerja lebih detail pada *test set* akan dibahas pada bagian Evaluasi Model.

4.2.3 Pembangunan Model CLIP

Sebagai pendekatan kedua dan lebih modern, model *Contrastive Language-Image Pre-Training* (CLIP) diimplementasikan. CLIP dipilih karena kemampuannya yang unik dalam menghubungkan pemahaman visual (gambar) dengan pemahaman tekstual (bahasa), yang diharapkan dapat memberikan representasi fitur yang lebih kaya untuk

klasifikasi tumor otak. Pembangunan model ini memanfaatkan *library* PyTorch dan Transformers, dengan proses komputasi yang diakselerasi menggunakan *Graphics Processing Unit* (GPU) melalui CUDA, sebagaimana terkonfirmasi dari *output log* (Device yang digunakan: cuda).

a. Arsitektur Model CLIP:


Implementasi model CLIP dalam penelitian ini melibatkan beberapa komponen kunci yang dirancang khusus:

1. BrainTumorDataset.

Komponen ini merupakan sebuah kelas *dataset custom* yang bertugas memuat citra MRI dan labelnya, serta melakukan transformasi yang diperlukan untuk input CLIP. Keunikan kelas ini adalah kemampuannya untuk mengkonversi citra *grayscale* menjadi format RGB (yang diharapkan oleh model CLIP *pre-trained*) dan, yang terpenting, menggabungkan setiap citra dengan *template* teks deskriptif yang relevan secara medis. *Template* teks ini (misalnya, 'a medical brain MRI scan showing glioma brain tumor...') dipilih secara acak untuk setiap sampel selama pemuatan data. Penggunaan deskripsi tekstual yang bervariasi ini bertujuan untuk meningkatkan *robustness* dan memanfaatkan sepenuhnya kapabilitas multimodal CLIP, memungkinkan model tidak hanya melihat gambar tetapi juga "memahami" konteksnya.

2. CLIPClassifier.

Sebuah arsitektur *classifier* dibangun di atas model CLIP *pre-trained* standar (openai/clip-vit-base-patch32). Arsitektur ini tidak hanya menggunakan fitur gambar atau teks secara terpisah, tetapi menggabungkan *image embeds* dan *text embeds* (dengan strategi *average fusion*). Fitur gabungan ini kemudian dinormalisasi dan dilewatkan melalui serangkaian lapisan *fully connected* tambahan yang dilengkapi dengan fungsi aktivasi ReLU dan *regularization* (Dropout). Lapisan tambahan ini bertujuan untuk memetakan fitur CLIP ke ruang kelas tumor otak secara spesifik. Opsi untuk "membekukan" (*freeze*) bobot CLIP juga disediakan untuk memungkinkan *fine-tuning* yang lebih terkontrol.



Gambar 4.2.3.1. Arsitektur Classifier CLIP

3. Fungsi Pelatihan dan Evaluasi.

Fungsi *custom* (*train_clip_model* dan *evaluate_clip_model*) dikembangkan untuk mengelola proses pelatihan. Fungsi ini mengimplementasikan teknik-teknik modern seperti *learning rate scheduler* (CosineAnnealingLR) untuk penyesuaian *learning rate* yang dinamis, *label smoothing* pada *loss function* untuk *regularization*, *gradient clipping* untuk menjaga stabilitas pelatihan, dan mekanisme *early stopping* untuk mencegah *overfitting* dan meningkatkan efisiensi waktu pelatihan.

4.2.4 Pelatihan Model CLIP

Untuk mendapatkan performa optimal dari arsitektur CLIPClassifier, langkah krusial adalah menemukan konfigurasi *hyperparameter* terbaik. Proses ini dilakukan melalui *Grid Search*, di mana berbagai kombinasi *hyperparameter* diuji secara sistematis. Parameter yang diuji dalam *Grid Search* ini meliputi:

1. Epochs: [25, 50]
2. Learning Rate (LR): [1e-2 (0.01), 1e-3 (0.001)]
3. Optimizer: [adamw]
4. Batch Size: [32, 64]
5. Freeze CLIP: [True (Bobot CLIP dibekukan), False (Dilakukan *fine-tuning*)]
6. Weight Decay: [0.01]

Total terdapat 16 kombinasi yang dievaluasi. Untuk setiap kombinasi, model dilatih dari awal, dan kinerjanya dipantau berdasarkan akurasi tertinggi yang dicapai pada *validation set*. Mekanisme *Early Stopping* dengan *patience 5 epoch* diaktifkan untuk mencegah *overfitting* dan efisiensi waktu. Hasil lengkap dari proses *Grid Search* ini disajikan pada Tabel 4.2.1.

Tabel 4.2.1 Kombinasi Hyperparameter Tuning CLIP

Kombinasi	Batch Size	Epochs	Freeze Clip	LR	Optimizer	Weight Decay	Epoch Stop	Time (s)	Val Acc
1	32	25	true	0.01	adamw	0.01	6	225.86	1.0000
2	32	25	true	0.001	adamw	0.01	6	222.60	1.0000
3	32	25	false	0.01	adamw	0.01	6	378.68	0.2847
4	32	25	false	0.001	adamw	0.01	6	376.49	1.0000
5	32	50	true	0.01	adamw	0.01	6	219.64	1.0000
6	32	50	true	0.001	adamw	0.01	6	221.49	1.0000
7	32	50	false	0.01	adamw	0.01	6	376.01	0.2847
8	32	50	false	0.001	adamw	0.01	6	375.96	1.0000
9	64	25	true	0.01	adamw	0.01	6	225.75	1.0000
10	64	25	true	0.001	adamw	0.01	6	216.25	1.0000
11	64	25	false	0.01	adamw	0.01	6	358.42	0.2847
12	64	25	false	0.001	adamw	0.01	6	364.27	1.0000
13	64	50	true	0.01	adamw	0.01	6	216.81	1.0000
14	64	50	true	0.001	adamw	0.01	6	216.98	1.0000
15	64	50	false	0.01	adamw	0.01	6	362.48	0.2847
16	64	50	false	0.001	adamw	0.01	6	363.81	1.0000

Proses *Grid Search* untuk menemukan *hyperparameter* optimal model CLIP, sebagaimana dirangkum pada Tabel 4.2.1, menghasilkan beberapa temuan penting. Hasil yang paling menonjol adalah pencapaian akurasi validasi 100% oleh 12 dari 16 kombinasi yang diuji. Ini menunjukkan kapasitas tinggi model CLIP, baik saat bobotnya dibekukan maupun saat di-*fine-tuning* (dengan *learning rate* 0.001), untuk mempelajari pola pada *validation set* secara efektif. Namun, terlihat jelas bahwa proses *fine-tuning* sangat sensitif terhadap *learning rate*; penggunaan LR tinggi (0.01) saat bobot CLIP tidak dibekukan (Freeze Clip = False) secara konsisten gagal (akurasi ~28.5%), yang kemungkinan besar disebabkan oleh ketidakstabilan atau *catastrophic forgetting* saat mengubah bobot *pre-trained* secara agresif.

Fakta bahwa semua kombinasi, termasuk yang mencapai 100%, berhenti pada *epoch* ke-6 akibat mekanisme *early stopping*, juga memerlukan perhatian khusus. Meskipun

ini menunjukkan efisiensi karena pelatihan tidak perlu berjalan hingga *epoch* maksimum, pencapaian 100% yang sangat cepat ini menimbulkan pertanyaan mengenai potensi *overfitting* pada *validation set* atau kemungkinan *validation set* yang terlalu "mudah" bagi model. Oleh karena itu, validasi sesungguhnya akan sangat bergantung pada hasil evaluasi pada *test set* yang sepenuhnya terpisah. Mengingat banyaknya model yang mencapai kinerja puncak, Kombinasi 10 (Batch Size: 64, Epochs: 25, Freeze Clip: True, LR: 0.001) dipilih sebagai konfigurasi terbaik untuk evaluasi selanjutnya, karena menawarkan akurasi 100% dengan waktu pelatihan tercepat (216.25 detik) dan konfigurasi yang cenderung stabil (bobot beku, LR rendah).


Berdasarkan hasil *Grid Search*, model CLIP dengan konfigurasi terbaik dari Kombinasi 10 ({ 'batch_size': 64, 'epochs': 25, 'freeze_clip': True, 'learning_rate': 0.001, 'optimizer': 'adamw', 'weight_decay': 0.01 }) berhasil mencapai akurasi validasi 100.00%. Model inilah yang kemudian akan digunakan untuk tahap evaluasi akhir pada *test set*, untuk menguji kemampuan generalisasinya pada data yang sepenuhnya baru dan belum pernah dilihat sebelumnya selama proses latihan maupun *tuning*.

4.3 Visualisasi Hasil Model

Setelah model SVM dan CLIP dibangun dan dilatih (dengan parameter terbaik untuk CLIP ditentukan melalui *Grid Search*), langkah selanjutnya adalah mengevaluasi dan memvisualisasikan kinerja mereka pada Test Set. *Test set* berisi data yang sepenuhnya baru dan belum pernah dilihat oleh model selama pelatihan maupun validasi, sehingga memberikan ukuran kinerja generalisasi yang paling objektif. Bagian ini berfokus pada penyajian hasil secara visual melalui *confusion matrix*, contoh prediksi, dan grafik perbandingan.

4.3.1 Visualisasi Kinerja Model CLIP

Model CLIP, menggunakan konfigurasi *hyperparameter* terbaik yang ditemukan melalui *Grid Search*, juga dievaluasi pada *test set*. Hasilnya disajikan pada *confusion matrix* di Gambar 4.3.1.5.



Gambar 4.3.1.5 Confusion Matrix Model CLIP

Gambar 4.3.1.5 menyajikan *confusion matrix* yang dihasilkan oleh model CLIP pada *test set*. Hasil yang ditampilkan sangat luar biasa dan menunjukkan kinerja yang sempurna. Matriks ini memiliki struktur yang ideal: semua nilai terkonsentrasi pada diagonal utama, dan semua elemen di luar diagonal (off-diagonal) bernilai nol.

Hal ini secara definitif mengindikasikan bahwa model CLIP berhasil mengklasifikasikan setiap sampel pada *test set* dengan benar, tanpa membuat satupun kesalahan. Model ini mencapai akurasi 100%, serta Presisi, Recall, dan F1-Score sebesar 1.0 (atau 100%) untuk setiap kelas individual.


Secara rinci:

1. 325 sampel glioma diprediksi dengan benar sebagai glioma.
2. 329 sampel meningioma diprediksi dengan benar sebagai meningioma.
3. 400 sampel notumor diprediksi dengan benar sebagai notumor.
4. 351 sampel pituitary diprediksi dengan benar sebagai pituitary.

Tidak ada kasus *false positive* (sampel yang salah diprediksi sebagai kelas tertentu) maupun *false negative* (sampel yang gagal dikenali sebagai kelas aslinya). Ini menunjukkan bahwa model CLIP, dengan arsitektur dan *hyperparameter* yang telah dioptimalkan melalui *Grid Search*, memiliki kemampuan diskriminasi yang sangat tinggi. Model ini mampu membedakan dengan sempurna antara kelas-kelas tumor yang berbeda, serta membedakannya dari citra otak normal, bahkan untuk kelas-kelas yang sebelumnya terbukti sulit bagi model SVM.


Kinerja 100% ini menegaskan efektivitas tinggi dari pendekatan CLIP yang menggabungkan fitur visual dan tekstual. Pengetahuan yang didapat dari *pre-training* skala besar, ditambah dengan deskripsi teks medis yang spesifik, tampaknya memberikan representasi fitur yang sangat *robust* dan akurat, memungkinkan model mencapai tingkat presisi yang sempurna pada dataset uji ini. Meskipun hasil ini sangat mengesankan, pentingnya validasi lebih lanjut pada dataset eksternal tetap menjadi pertimbangan untuk memastikan generalisasi di dunia nyata. Namun, berdasarkan *test set* yang digunakan, model CLIP menunjukkan performa yang optimal.

Setelah mengidentifikasi Kombinasi 10 sebagai konfigurasi *hyperparameter* terbaik berdasarkan *Grid Search*, penting untuk menganalisis bagaimana model ini berperilaku selama proses pelatihannya. Gambar 4.3.1.3 dan 4.3.1.4 di bawah ini menyajikan kurva *training loss* dan akurasi validasi untuk model CLIP terbaik selama 6 *epoch* pelatihannya (sebelum dihentikan oleh *Early Stopping*).



Gambar 4.3.1.3 Training Loss pada Model CLIP

Gambar 4.3.1.3 menunjukkan kurva *training loss* dari model CLIP terbaik. Terlihat penurunan *loss* yang sangat tajam pada dua *epoch* pertama, di mana nilai *loss* turun dari sekitar 0.51 menjadi sekitar 0.37. Penurunan ini mengindikasikan bahwa model belajar dengan sangat cepat pada tahap awal, mampu menyesuaikan bobotnya secara signifikan untuk meminimalkan kesalahan pada data latih. Setelah *epoch* kedua, kurva menjadi lebih landai, dengan *loss* terus menurun secara perlahan hingga mencapai nilai sekitar 0.36 pada *epoch* ke-6. Ini menunjukkan bahwa model telah mencapai titik konvergensi atau mendekatinya, di mana peningkatan lebih lanjut pada data latih menjadi lebih sulit dicapai. Secara keseluruhan, kurva ini mencerminkan proses pelatihan yang efektif dan efisien.




Gambar 4.3.1.4 Akurasi Validasi pada Model CLIP

Gambar 4.3.1.4 menampilkan kurva akurasi pada *validation set* untuk model yang sama. Hasil yang ditampilkan sangat konsisten dengan temuan *Grid Search*: model langsung mencapai akurasi 100% (1.0) sejak *epoch* pertama dan mempertahankan tingkat akurasi sempurna ini selama 6 *epoch*. Kurva yang datar pada nilai 1.0 ini adalah alasan mengapa mekanisme *Early Stopping* menghentikan pelatihan pada *epoch* ke-6; tidak ada lagi ruang untuk peningkatan akurasi validasi. Seperti yang telah dibahas sebelumnya, meskipun ini menunjukkan kapasitas model yang sangat tinggi untuk mempelajari data validasi, hasil 100% yang instan ini juga menjadi dasar mengapa evaluasi pada *test set* menjadi sangat krusial untuk memverifikasi kemampuan generalisasi model dan memastikan tidak terjadi *overfitting* yang tersembunyi.

4.3.2 Visualisasi Kinerja Model SVM

Model SVM *baseline*, setelah dilatih menggunakan fitur hasil ekstraksi PCA, dievaluasi kinerjanya pada *test set*. Untuk memvisualisasikan performa klasifikasi secara detail, terutama dalam melihat bagaimana model membedakan (atau gagal membedakan) antar kelas, *confusion matrix* disajikan pada Gambar 4.3.2.1



Gambar 4.3.2.1 Confusion Matrix Model SVM


Visualisasi kinerja model SVM *baseline* pada *test set*, seperti yang ditunjukkan oleh *confusion matrix* pada Gambar 4.5, menyajikan gambaran performa yang cukup baik namun dengan beberapa area kelemahan yang jelas. Model ini menunjukkan efektivitas tertinggi pada kelas 'notumor' dan 'pituitary', dengan nilai Recall masing-masing mencapai 94.8% (379 dari 400 benar) dan 96.9% (340 dari 351 benar). Keberhasilan ini mengindikasikan kemampuan SVM dalam mengenali pola citra otak normal yang cenderung konsisten dan fitur khas citra pituitary, yang mungkin terkait dengan lokasinya yang spesifik.

Namun, performa model menurun signifikan saat dihadapkan pada kelas 'meningioma', yang hanya mencapai Recall 77.8% (256 dari 329 benar) dan menunjukkan tingkat kebingungan tertinggi; sampel 'meningioma' salah diklasifikasikan ke semua kelas lain, terutama ke 'glioma' (31 kasus) dan 'pituitary' (24 kasus). Kebingungan paling menonjol dan bersifat dua arah teramati antara kelas 'glioma' dan 'meningioma', di mana 36 sampel 'glioma' juga salah diprediksi sebagai 'meningioma'. Hal ini menegaskan adanya tumpang tindih fitur visual yang signifikan antara kedua jenis tumor ini, yang sulit dipisahkan oleh *hyperplane* SVM ketika hanya mengandalkan fitur hasil ekstraksi PCA.

Secara keseluruhan, *confusion matrix* ini mengonfirmasi bahwa meskipun SVM *baseline* memiliki kapabilitas dasar untuk klasifikasi, ia menunjukkan keterbatasan yang nyata dalam menangani kompleksitas dan kemiripan visual antar kelas tumor otak. Kinerja ini menyoroti perlunya pendekatan dengan representasi fitur yang lebih kuat dan diskriminatif untuk dapat mencapai akurasi yang lebih tinggi, seperti yang diharapkan dari model CLIP.


4.3.3 Perbandingan Kinerja Visual SVM vs CLIP

Grafik ini menunjukkan perbandingan kinerja keseluruhan antara model CLIP dan SVM berdasarkan empat metrik evaluasi utama: akurasi, presisi, recall, dan F1-score. Model CLIP secara konsisten mengungguli SVM di semua metrik, menandakan bahwa CLIP lebih andal dalam klasifikasi gambar secara umum.




Gambar 4.3.3.1 Grafik Perbandingan Model secara Keseluruhan

Grafik ini memperlihatkan perbandingan nilai precision per kelas antara model CLIP dan SVM. CLIP menunjukkan precision yang lebih tinggi di hampir semua kelas, menandakan bahwa prediksi positifnya lebih relevan dibandingkan SVM. SVM mengalami precision rendah khususnya pada beberapa kelas minoritas.




Gambar 4.3.3.2 Grafik Perbandingan Precision berdasarkan Kelas

Perbandingan recall memperlihatkan bahwa model CLIP berhasil mengenali lebih banyak sampel positif sebenarnya di sebagian besar kelas dibandingkan SVM. Ini menunjukkan bahwa CLIP lebih baik dalam menangkap keberadaan kelas target.




Gambar 4.3.3.3 Grafik Perbandingan Recall berdasarkan Kelas

Grafik ini memperlihatkan gabungan kekuatan precision dan recall dalam bentuk F1-score untuk setiap kelas. CLIP kembali unggul di hampir seluruh kelas, mencerminkan kestabilan dan keseimbangan performa dalam deteksi kelas.




Gambar 4.3.3.4 Grafik Perbandingan F1-Score berdasarkan Kelas

Grafik ini menampilkan ringkasan metrik rata-rata untuk kedua model. CLIP menunjukkan performa rata-rata yang jauh lebih baik, menegaskan hasil yang terlihat di grafik sebelumnya bahwa model ini lebih unggul secara keseluruhan dibandingkan SVM.




Gambar 4.3.3.5 Grafik Perbandingan Keseluruhan Model

Grafik bar ini merangkum performa akhir dari CLIP dan SVM dalam satu tampilan ringkas. CLIP menunjukkan nilai metrik yang tinggi dan konsisten, sedangkan SVM tampak lebih fluktuatif dan tertinggal cukup jauh di semua metrik.




Gambar 4.3.3.6 Grafik Perbandingan Akurasi Tes Model SVM dan CLIP

Matrix ini menunjukkan bahwa SVM mengalami kebingungan tinggi antar kelas, dengan banyak prediksi yang tidak sesuai dengan label sebenarnya. Beberapa kelas bahkan memiliki distribusi prediksi yang menyebar, menandakan ketidakmampuan model dalam membedakan fitur antar kelas.




Gambar 4.3.3.7 Confusion Matrix SVM Setelah Normalisasi

Sebaliknya, matriks normalisasi untuk CLIP menunjukkan distribusi prediksi yang lebih terpusat di diagonal utama. Ini menunjukkan bahwa CLIP mampu mengenali dan mengklasifikasikan gambar dengan lebih akurat dibandingkan SVM.




Gambar 4.3.3.8 Confusion Matrix CLIP Setelah Normalisasi

Grafik ini menunjukkan jumlah kesalahan klasifikasi per kelas. CLIP menghasilkan lebih sedikit error secara signifikan dibandingkan SVM. Kesalahan pada SVM terdistribusi hampir merata, sedangkan CLIP hanya mengalami error kecil pada sebagian kecil kelas.



Gambar 4.3.3.9 Grafik Perbandingan Jumlah Error pada Model SVM dan CLIP

Grafik ini menggambarkan persentase peningkatan performa CLIP dibandingkan SVM pada tiap metrik. Peningkatan terbesar terlihat pada F1-score dan recall, menandakan bahwa CLIP tidak hanya lebih tepat dalam prediksi, tetapi juga lebih menyeluruh dalam mencakup data positif.



Gambar 4.3.3.10 Grafik Persentase Peningkatan Model SVM dan CLIP

4.4 Evaluasi Model

Evaluasi model dilakukan untuk mengetahui seberapa baik performa dari masing-masing model klasifikasi yang telah diuji, yaitu SVM dan CLIP. Penilaian tidak hanya didasarkan pada akurasi keseluruhan, tetapi juga mempertimbangkan metrik lain seperti precision, recall, dan F1-score. Metrik-metrik ini penting untuk menilai keseimbangan performa model pada masing-masing kelas, terutama dalam kasus data tidak seimbang atau ketika kesalahan klasifikasi memiliki dampak yang berbeda.

Evaluasi dilakukan menggunakan data uji yang sama untuk semua model agar perbandingan hasil menjadi adil dan objektif. Selain itu, hasil evaluasi divisualisasikan

melalui berbagai grafik komparatif agar memudahkan analisis dan interpretasi performa antar model secara menyeluruh.

4.4.1 Nilai Evaluasi dan Interpretasi

Tabel 4.4.1 Perbandingan Nilai Precision SVM dan CLIP

Kelas	SVM Precision	CLIP Precision	Δ Precision
Glioma	0.8571	1.0000	+0.1429
Meningioma	0.8477	1.0000	+0.1523
No Tumor	0.9475	1.0000	+0.0525
Pituitary	0.9264	1.0000	+0.0736

Berdasarkan ketiga tabel evaluasi—precision, recall, dan F1-score—dapat disimpulkan bahwa model CLIP secara konsisten menunjukkan kinerja yang lebih unggul dibandingkan model SVM pada seluruh kelas data, yaitu glioma, meningioma, no tumor, dan pituitary.

Pada metrik Precision, model CLIP berhasil mencapai nilai sempurna (1.0000) di keempat kelas, menandakan bahwa setiap prediksi positif yang dilakukan oleh model CLIP selalu benar. Sebaliknya, model SVM memiliki precision yang bervariasi, dengan nilai tertinggi pada kelas *no tumor* (0.9475) dan terendah pada kelas *meningioma* (0.8477). Selisih precision terbesar terjadi pada kelas meningioma (+0.1523), menunjukkan bahwa CLIP jauh lebih akurat dalam mengidentifikasi kelas ini tanpa menghasilkan false positive.

Tabel 4.4.2 Perbandingan Nilai Recall SVM dan CLIP

Kelas	SVM Recall	CLIP Recall	Δ Recall
Glioma	0.8862	1.0000	+0.1138
Meningioma	0.7781	1.0000	+0.2219
No Tumor	0.9475	1.0000	+0.0525
Pituitary	0.9687	1.0000	+0.0313

Pada metrik Recall, model CLIP kembali mencatatkan performa sempurna (1.0000) pada semua kelas, yang berarti semua data aktual berhasil dikenali dengan tepat. Sebaliknya, SVM mengalami kesulitan khususnya pada kelas meningioma dengan recall

hanya 0.7781, mengindikasikan banyak kasus meningioma yang gagal dikenali. Kesenjangan recall tertinggi pun terjadi pada kelas ini (+0.2219), menegaskan bahwa CLIP jauh lebih andal dalam mendeteksi seluruh sampel kelas tersebut.

Tabel 4.4.3 Perbandingan Nilai F1-Score SVM dan CLIP

Kelas	SVM F1-score	CLIP F1-score	Δ F1-score
Glioma	0.8714	1.0000	+0.1286
Meningioma	0.8114	1.0000	+0.1886
No Tumor	0.9475	1.0000	+0.0525
Pituitary	0.9471	1.0000	+0.0529

Metrik F1-score sebagai gabungan antara precision dan recall menunjukkan gambaran umum performa model yang lebih seimbang. CLIP kembali unggul dengan skor sempurna di semua kelas. Sementara itu, SVM menunjukkan performa F1 tertinggi pada kelas *no tumor* (0.9475) dan terendah pada kelas *meningioma* (0.8114). Selisih terbesar terjadi pada kelas meningioma (+0.1886), memperkuat temuan bahwa model SVM paling lemah dalam menangani kelas ini dibandingkan CLIP.

Berdasarkan hasil evaluasi, model CLIP menunjukkan performa yang lebih unggul dibandingkan SVM pada hampir seluruh metrik. Dari grafik perbandingan, terlihat bahwa CLIP memiliki nilai precision, recall, dan F1-score yang lebih tinggi di setiap kelas, khususnya pada kelas *meningioma* dan *pituitary* yang sebelumnya menjadi tantangan bagi model SVM. Selain itu, confusion matrix dari kedua model memperlihatkan bahwa CLIP mampu meminimalkan jumlah prediksi yang salah, sedangkan SVM masih menunjukkan kesalahan yang cukup tinggi dalam membedakan kelas *glioma* dan *meningioma*. Model CLIP juga menunjukkan perbaikan signifikan pada jumlah kesalahan prediksi, dengan total kesalahan yang lebih rendah dibandingkan SVM.

Secara keseluruhan, model CLIP tidak hanya unggul dalam akurasi total, tetapi juga lebih stabil dalam mengenali tiap kelas dengan baik. Hal ini membuktikan bahwa model berbasis deep learning seperti CLIP lebih efektif dalam mengekstraksi dan memahami fitur kompleks dari citra MRI otak dibandingkan metode klasik seperti SVM.

4.5 Analisis Hasil

4.5.1 Analisis Kinerja Support Vector Machine (SVM)

Model SVM menunjukkan kinerja yang cukup baik, namun memiliki beberapa kelemahan yang jelas. Berdasarkan hasil pada confusion matrix (Gambar 4.3.2.1), model ini paling berhasil mengenali kelas no tumor. Ini menandakan bahwa ciri-ciri visual dari gambar otak normal cukup berbeda sehingga mudah dikenali oleh SVM.

Namun, kelemahan utama SVM terlihat saat harus membedakan kelas tumor yang gambarnya mirip, yaitu glioma dan meningioma. Model ini sering keliru mengklasifikasikan glioma sebagai meningioma, dan sebaliknya. Kelas meningioma menjadi yang paling sulit dikenali, dengan tingkat keberhasilan (Recall) paling rendah, yaitu hanya 77.81%.

Kesalahan ini terjadi karena cara kerja SVM yang mendasarkan klasifikasi pada fitur visual yang diekstraksi, tanpa memahami konteks gambar secara mendalam. Ketika dua jenis tumor memiliki tekstur atau bentuk yang serupa, model menjadi bingung oleh kemiripan visual tersebut.

4.5.2 Analisis Kinerja Contrastive Language Image Pretraining (CLIP)

Sebaliknya, model CLIP menunjukkan hasil yang jauh lebih unggul dan berhasil mencapai kinerja sempurna. Pada confusion matrix (Gambar 4.3.1.5), terlihat bahwa CLIP tidak membuat satupun kesalahan klasifikasi pada seluruh data uji. Hal ini menghasilkan nilai akurasi, presisi, recall, dan F1-score sebesar 100% untuk semua kelas.

Keberhasilan ini disebabkan oleh arsitektur CLIP yang unik, yang tidak hanya menganalisis gambar, tetapi juga menghubungkannya dengan deskripsi teks yang sesuai. Kemampuan ini memungkinkan CLIP untuk "memahami" konteks gambar, sehingga bisa membedakan fitur-fitur yang sangat mirip sekalipun, yang tidak dapat dilakukan oleh SVM.

Hasil kurva pelatihan (Gambar 4.3.1.3 dan 4.3.1.4) juga mendukung temuan ini. Model CLIP belajar dengan sangat cepat dan mencapai akurasi maksimal sejak awal. Hal ini menunjukkan bahwa model CLIP tidak memerlukan waktu lama untuk belajar karena sudah memiliki pengetahuan dasar dari proses *pre-training* pada data yang sangat besar. Data besar yang digunakan untuk *pre-training* model CLIP oleh OpenAI adalah dataset internal pihak OpenAI yang disebut WebImageText (WIT). Dataset ini terdiri dari sekitar 400 juta pasangan gambar dan teks yang dikumpulkan secara otomatis dari berbagai sumber publik di internet. Proses *pre-training* yang ekstensif dengan dataset WIT ini membekali CLIP dengan pemahaman visual dan hubungan semantik yang kaya. Akibatnya, ketika model ini dilatih lebih lanjut untuk tugas spesifik (seperti klasifikasi tumor otak), ia tidak memulai dari nol.

4.5.3 Perbandingan Kinerja SVM dan CLIP

Perbandingan langsung antara SVM dan CLIP menunjukkan perbedaan mendasar dalam cara kerja dan hasil akhir.

1. Perbedaan kinerja paling jelas terlihat pada kelas meningioma. CLIP mampu mengenali semua sampel meningioma dengan benar (Recall 100%), sementara SVM gagal mengenal sekitar 23% sampel. Ini membuktikan kemampuan CLIP dalam mengatasi masalah kemiripan gambar yang menjadi kelemahan SVM.
2. Kinerja SVM naik-turun tergantung pada kelasnya. Sebaliknya, CLIP memberikan hasil sempurna secara konsisten di semua kelas. Ini menunjukkan bahwa CLIP adalah model yang lebih stabil dan dapat diandalkan.
3. Grafik jumlah kesalahan (Gambar 4.3.3.9) secara jelas menunjukkan bahwa SVM masih membuat banyak kesalahan prediksi, sementara CLIP tidak membuat satupun kesalahan. Dalam konteks medis, hasil tanpa kesalahan tentu jauh lebih diharapkan.
4. Keunggulan CLIP disebabkan oleh dua hal utama: arsitektur *deep learning* modern yang dapat mengenali pola kompleks, dan kemampuannya memproses gambar dan teks sekaligus (*multimodal*). SVM, sebagai metode klasik, tidak memiliki kemampuan tersebut.

BAB V

KESIMPULAN

5.1 Ringkasan Hasil Percobaan

Berdasarkan hasil eksperimen klasifikasi tumor otak menggunakan citra MRI, metode *Contrastive Language-Image Pretraining* (CLIP) terbukti secara signifikan lebih unggul dibandingkan *Support Vector Machine* (SVM) dalam seluruh metrik evaluasi. CLIP mencapai akurasi 100% pada data testing dengan confusion matrix yang menunjukkan klasifikasi sempurna pada keempat kelas (*glioma*, *meningioma*, *pituitary*, dan no tumor) tanpa kesalahan prediksi. Sebaliknya, SVM hanya mencapai akurasi 89,47% dan mengalami sejumlah kesalahan klasifikasi, terutama pada kelas *glioma* dan *meningioma* yang memiliki kemiripan fitur visual. Keunggulan CLIP berasal dari kemampuannya memahami pola visual secara global dan abstrak melalui arsitektur transformer serta pemanfaatan data multimodal berupa citra dan teks. Sementara itu, SVM hanya mengandalkan ciri tekstur atau bentuk lokal, sehingga cenderung kesulitan membedakan fitur kompleks pada citra medis.

5.2 Saran

1. Eksplorasi Teknik Augmentasi dan Preprocessing Lanjutan

Untuk meningkatkan kemampuan generalisasi model, penelitian selanjutnya dapat mencoba berbagai teknik augmentasi lanjutan seperti elastic deformation, histogram equalization, Gaussian noise injection, atau random cropping. Pendekatan ini akan membuat model lebih tangguh terhadap variasi bentuk, tekstur, dan kontras dalam citra MRI — terutama dalam kondisi nyata di mana kualitas gambar tidak selalu optimal.

2. Pengujian Model pada Dataset Eksternal atau Data Klinik Nyata

Disarankan untuk menguji performa model CLIP dan SVM pada dataset dari sumber eksternal seperti rumah sakit atau institusi medis lainnya. Pengujian ini penting untuk mengukur daya generalisasi dan keandalan model pada data dunia nyata yang mungkin mengandung noise, artefak pemindaian, atau distribusi kelas yang tidak seimbang.

3. Integrasi Data Multimodal dan Rekam Medis Elektronik (EMR)

Penggabungan data citra dengan data klinis non-visual seperti hasil lab, catatan medis elektronik (EMR), atau deskripsi gejala dapat membuka peluang pengembangan sistem diagnosis berbasis AI yang lebih lengkap dan informatif. CLIP memiliki potensi besar dalam menangani data multimodal ini karena kemampuannya menggabungkan pemahaman gambar dan teks secara bersamaan.

4. Pemanfaatan Model AI Generatif Mutakhir seperti GPT-4.5 dan Veo 3
Untuk tahap pengembangan lanjut, khususnya dalam aplikasi industri, penggunaan model mutakhir seperti GPT-4.5 dapat dimanfaatkan untuk menganalisis hasil klasifikasi, menjelaskan keputusan model (XAI), atau membangun sistem dialog interaktif antara AI dan tenaga medis. Selain itu, model video generatif seperti Veo 3 dari Google dapat dimanfaatkan dalam simulasi atau pelatihan medis berbasis citra MRI, seperti visualisasi perkembangan tumor dari waktu ke waktu.
5. Implementasi dalam Sistem Industri Kesehatan
Penelitian ini berpotensi untuk dikembangkan menjadi aplikasi klinis berbasis AI yang dapat diintegrasikan ke dalam sistem informasi rumah sakit (SIR), PACS (Picture Archiving and Communication System), atau perangkat lunak radiologi. Untuk mendukung hal ini, dibutuhkan optimalisasi model dari sisi kecepatan inferensi, efisiensi memori, serta keamanan dan privasi data pasien sesuai standar industri seperti HIPAA atau ISO 27001.

DAFTAR PUSTAKA

- [1] J. Liu *et al.*, "CLIP-Driven Universal Model for Organ Segmentation and Tumor Detection." [Online]. Available: <https://github.com/ljwztc/CLIP-Driven-Universal-Model>
- [2] X. Chen *et al.*, "Mammo-CLIP: Leveraging Contrastive Language-Image Pre-training (CLIP) for Enhanced Breast Cancer Diagnosis with Multi-view Mammography."
- [3] H. Zhang, H. Yi, S. Qin, X. Liu, and G. Liu, "CLIP-based multimodal endorectal ultrasound enhances prediction of neoadjuvant chemoradiotherapy response in locally advanced rectal cancer," *PLoS ONE*, vol. 19, no. 12 December, Dec. 2024, doi: 10.1371/journal.pone.0315339.
- [4] A. Shabrina Febrianti, "FINAL PROJECT-EB184803 CLASSIFICATION OF BRAIN TUMORS IN MAGNETIC RESONANCE IMAGE (MRI) USING SUPPORT VECTOR MACHINE (SVM) METHOD UNDERGRADUATE PROGRAM BIOMEDICAL ENGINEERING DEPARTMENT FACULTY OF INTELLIGENT ELECTRICAL AND INFORMATICS TECHNOLOGY SEPULUH NOPEMBER INSTITUTE OF TECHNOLOGY SURABAYA 2020."
- [5] T. Z. Li *et al.*, "Contrastive Patient-level Pretraining Enables Longitudinal and Multimodal Fusion for Lung Cancer Risk Prediction," 2025. [Online]. Available: <https://github.com/MASILab/lung-cplp>.
- [6] "20081010231_bab1".
- [7] Wahyu Ardiantito S, Stacyana Jesika Surianto, Suci Ramadhani, and Willy Pramudia Ananta, "Klasifikasi Tumor Otak Menggunakan Local Binary Pattern dan SVM Classifier," *Student Research Journal*, vol. 1, no. 6, pp. 182–190, Dec. 2023, doi: 10.55606/srjyappi.v1i6.823.
- [8] Z. Liu *et al.*, "SeLIP: Similarity Enhanced Contrastive Language Image Pretraining for Multi-modal Head MRI," Mar. 2025, [Online]. Available: <http://arxiv.org/abs/2503.19801>
- [9] R. E. Altarazi, M. S. Hamad, R. Elbanna, D. Elborno, and S. S. Abu-Naser, "A CLIPS-Based Expert System for Brain Tumor Diagnosis," *International Journal of Academic Engineering Research*, [Online]. Available: www.ijeais.org/ijeais
- [10] J. S. Ananda, Y. Fendriani, and J. Pebralia, "CLASSIFICATION ANALYSIS OF BRAIN TUMOR DISEASE IN RADIOGRAPHIC IMAGES USING SUPPORT VECTOR MACHINES (SVM) WITH PYTHON," *JoP*, vol. 9, no. 3, pp. 110–115, 2024.
- [11] D. Jung, J. Jang, S. Jang, and Y. R. Park, "MEDFORM: A Foundation Model for Contrastive Learning of CT Imaging and Clinical Numeric Data in Multi-Cancer Analysis." [Online]. Available: <https://github.com/DigitalHealthcareLab/25MultiModalFoundationModel.git>
- [12] A. J. Sinulingga, D. Robinson Manalu, and S. Manurung, "KLASIFIKASI JENIS TUMOR OTAK BERDASARKAN CITRA GLIOMA MENGGUNAKAN METODE SUPPORT VECTOR MACHINE," *Jurnal METHODIKA*, vol. 9, no. 2, 2023.
- [13] C. Gunasundari and K. Selva Bhuvaneswari, "Machine learning fusion for glioma tumor detection," *Scientific Reports*, vol. 15, no. 1, Dec. 2025, doi: 10.1038/s41598-025-89911-3.
- [14] Y. Jiang *et al.*, "CliP: subclonal architecture reconstruction of cancer cells in DNA sequencing data using a penalized likelihood model." Apr. 02, 2021, doi: 10.1101/2021.03.31.437383.
- [15] "MRI interpretation - T1 v T2 images," Radiology Masterclass. [Online]. Available: https://www.radiologymasterclass.co.uk/tutorials/mri/t1_and_t2_images. [Accessed: May 28, 2025]
- [16] Magnetic Resonance Imaging - Special Subjects," Merck Manuals. [Online]. Available: <https://www.merckmanuals.com/professional/special-subjects/principles-of-radiologic-imaging/magnetic-resonance-imaging>. [Accessed: May 28, 2025]
- [17] A. M. Tahaa, S. A. Aly, and M. F. Darwish, "Detecting Glioma, Meningioma, and Pituitary Tumors, and Normal Brain Tissues based on Yolov11 and Yolov8 Deep Learning Models," arXiv preprint arXiv:2504.00189, 2025. [Online]. Available: <https://arxiv.org/html/2504.00189v1>
- [18] X. Liu and Z. Wang, "Deep Learning in Medical Image Classification from MRI-based Brain Tumor Images," arXiv preprint arXiv:2408.00636, 2024. [Online]. Available: <https://arxiv.org/abs/2408.00636>
- [19] MathWorks, "Medical Image Preprocessing - MATLAB & Simulink," [Online]. Available: <https://www.mathworks.com/help/medical-imaging/ug/overview-medical-image-preprocessing.html>. [Accessed: May 28, 2025].
- [20] J. C. Reinhold, B. E. Dewey, A. Carass, and J. L. Prince, "Evaluating the Impact of Intensity Normalization on MR Image Synthesis," *arXiv preprint arXiv:1812.04652*, 2018. [Online]. Available: <https://arxiv.org/abs/1812.04652>. [Accessed: May 28, 2025].
- [21] A. Kebaili, J. Lapuyade-Lahorgue, and S. Ruan, "Deep Learning Approaches for Data Augmentation in Medical Imaging: A Review," *arXiv preprint arXiv:2307.13125*, 2023. [Online]. Available: <https://arxiv.org/abs/2307.13125>. [Accessed: May 28, 2025].

- [22] M. A. L. Khaniki, M. Mirzaeibonehkhater, M. Manthouri, and E. Hasani, "Brain Tumor Classification using Vision Transformer with Selective Cross-Attention Mechanism and Feature Calibration," *arXiv preprint arXiv:2406.17670*, Jun. 2024. [Online]. Available: <https://arxiv.org/abs/2406.17670>
- [23] A. Radford *et al.*, "Learning Transferable Visual Models From Natural Language Supervision," *arXiv preprint arXiv:2103.00020*, Mar. 2021. [Online]. Available: <https://arxiv.org/abs/2103.00020>
- [24] Z. Zhao *et al.*, "CLIP in Medical Imaging: A Comprehensive Survey," *arXiv preprint arXiv:2312.07353*, 2023. [Online]. Available: <https://arxiv.org/abs/2312.07353>
- [25] L. Mishra, S. Verma, and S. Varma, "Hybrid Model using Feature Extraction and Non-linear SVM for Brain Tumor Classification," *arXiv preprint arXiv:2212.02794*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.02794>. [Accessed: May 28, 2025].

LAMPIRAN

Figjam Brainstorming

<https://www.figma.com/board/5Vc4RoDlafXK0GWSocoS9V/IBM-Design-Thinking-Kelompok-6?node-id=0-1&t=pPJm1bnRZKXRvKsT-1>

Bukti Bimbingan

